

鏡面・ガラス反射環境における LiDAR 観測の 確率的デジタルツイン構築に関する研究計画

2026 年 7 月 18 日

1 研究目的

本研究では、鏡・ガラスを含む環境で取得された LiDAR 観測について、各点を単純に「残す／削除する」と決定するのではなく、

$$P(G_v = 1 \mid Z_{1:t}), \quad (1)$$

$$P(O_v = 1 \mid Z_{1:t}) \quad (2)$$

を別々に推定・保持する確率的デジタルツインを構築する。ここで、 G_v は voxel v に蓄積された観測が ghost 由来である事象、 O_v は voxel v が実際の物理表面によって占有されている事象、 $Z_{1:t}$ は時刻 1 から t までの観測を表す。

本研究では、観測点が物理的な占有の証拠としてどの程度信頼できるかを確率的に評価し、その信頼度を世界座標上で時空間的に統合する。これにより、ghost 点を物理障害物として誤登録することと、ghost らしい点を一律に削除することで実在物体を失うことの双方を抑制する。

また、ghost 点の発生は LiDAR 点単体の反射強度や return 情報だけでなく、鏡面・ガラス面の位置、境界および外観と関係する。このため本研究では、LiDAR のみを用いる単一モーダル手法と、LiDAR 点群およびカメラ画像を統合するマルチモーダル手法を構築し、両者の ghost 確率推定性能を比較する。

具体的には、LiDAR のみを用いた場合の点 i の ghost 確率を

$$q_{i,t}^L = P(G_{i,t} = 1 \mid Z_t^L) \quad (3)$$

とし、LiDAR およびカメラ画像を用いた場合の ghost 確率を

$$q_{i,t}^{LC} = P(G_{i,t} = 1 \mid Z_t^L, I_t) \quad (4)$$

とする。ここで、 Z_t^L は時刻 t の LiDAR 観測、 I_t は対応するカメラ画像である。

これらの確率を世界座標上の voxel へ時空間的に統合し、LiDAR のみの場合と LiDAR–Camera 融合の場合について、ghost 確率 $P(G_v = 1 \mid Z_{1:t})$ および物理占有確率 $P(O_v = 1 \mid Z_{1:t})$ の精度を比較する。

以上より、本研究の目的は以下のようにまとめられる。

LiDAR 観測点が鏡面反射による ghost である確率を推定し、その確率を世界座標上で時空間的に統合することで、反射環境における物理的占有状態の不確実性を表現する確率的デジタルツイン構築手法を提案する。さらに、LiDAR のみを用いる手法と LiDAR–Camera 融合手法を比較し、カメラ画像に含まれる鏡面・ガラス面の外観情報が ghost 確率推定および物理占有状態推定に与える効果を明らかにする。

1.1 使用するデータセットと出典

本研究では、主データセットとして 3DRef (*3D Dataset and Benchmark for Reflection Detection in RGB and Lidar Data*) [1] を使用する。3DRef は、鏡、ガラス、白板、モニタなどの反射面を含む屋内環境で取得された、RGB 画像、multi-return LiDAR 点群、2D/3D semantic label、LiDAR pose、ラベル付き 3D ground-truth mesh を含む公開データセットである。公式プロジェクトページでは、3 系列の屋内シーケンス、48,024 個のラベル付き LiDAR 点群、3,799 枚のラベル付き RGB 画像、Ouster、Livox、Hesai の 3 種類の LiDAR センサによるデータが提供されている。

本研究では、このうち LiDAR 点群、点単位の semantic label、LiDAR pose、ラベル付き 3D mesh を主に使用する。点単位ラベルは ghost 確率推定モデルの教師信号として用い、LiDAR pose は各点を世界座標系へ変換するために用いる。また、ラベル付き 3D mesh は物理占有状態の ground truth を構築するために利用する。

3DRef の公開ベンチマークでは、LiDAR 点群セグメンテーションとして MinkowskiNet、SPVCNN および Cylinder3D が比較され、return 情報を追加した Cylinder3D が全センサ統合条件で最も高い mIoU を示している [1]。したがって本研究では、Cylinder3D を再現可能な公式ベースラインとして使用し、後述する Transformer 型モデルと比較する。

2 関連研究と採用方針

近年の LiDAR–Camera 融合では、両モダリティを共通の Bird’s-Eye View (BEV) へ変換して統合する方法が 3D 物体検出および BEV map segmentation の主要な構成となっている [2]。しかし、本研究は屋内の壁面、鏡、ガラスおよびその前後に分布する点を点単位で分類するため、高さ方向を圧縮する BEV 表現を主表現とはしない。BEV 型手法の「共通座標で統合する」という原理を採用しつつ、3D point/voxel token を保持する。

LiDAR 特徴抽出には、屋内外の点群理解で高い性能と計算効率を示す PTv3 [3] を採用する。カメラ特徴抽出には、dense prediction に適した自己教師あり特徴を持つ DINOv3[4] を使用し、3DRef で再学習可能な反射面 segmentation モデル EBLNet[5] の出力を補助特徴として加える。

融合では、calibration に基づく単一点対応だけに依存せず、投影位置周辺から必要な画像特徴を選択する cross-attention を用いる。これは、LiDAR query による soft association を用いて画像劣化や位置ずれへの頑健性を高める TransFusion[6] の考え方を、点単位 reflection segmentation へ適用するものである。

時系列処理については、過去の LiDAR 点と画像特徴を pose 補償して利用する TASeg [7]、および共有 3D 位置符号化と cross-modal memory attention を用いる SAM4D[8] を参照する。ただし、3DRef は 3 系列であり大規模な end-to-end 時系列 Transformer は過学習しやすいため、本研究では短い時間窓に限定した Sparse Temporal Transformer とする。

3DRef 上では LiDAR–Camera 融合による点単位 reflection segmentation の標準的な leaderboard がまだ確立していない [1]。したがって、異なるタスクの最高値を直接「本研究の最高性能」とみなさず、Cylinder3D、PTv3、単純特徴連結、cross-attention、時系列統合を同一分割で段階的に比較する。

3 リサーチクエスチョン

本研究では、以下のリサーチクエスチョンを設定する。

RQ1 LiDAR の位置、反射強度および return 情報のみから、各観測点が ghost である確率をどの程度正確かつ適切に校正された形で推定できるか。

- RQ2 LiDAR 点群にカメラ画像の外観情報を統合することで、LiDAR のみを用いる場合と比較して、ghost 点の識別性能および確率校正性能は向上するか。
- RQ3 世界座標で整列した短時間の LiDAR 点特徴および画像特徴を Sparse Temporal Transformer で統合することで、単一フレームモデルと比較して ghost 点の識別性能と確率の時間的一貫性は向上するか。
- RQ4 LiDAR のみ、または LiDAR–Camera 融合によって推定した ghost 確率を世界座標上で時空間的に統合することで、通常の occupancy map やハードな ghost 点除去と比較して、ghost による偽の占有を抑制しつつ、実在する物体の占有状態を保持できるか。

4 推定対象とデータから得られる情報

4.1 観測レベル

時刻 t に取得された LiDAR 点群を

$$Z_t^L = \{z_{1,t}, \dots, z_{N_t,t}\} \quad (5)$$

とする。各 LiDAR 点は、

$$z_{i,t} = (x_{i,t}, y_{i,t}, z_{i,t}, I_{i,t}^L, r_{i,t}) \quad (6)$$

で表す。ここで、 (x, y, z) は LiDAR 座標系における位置、 I^L は LiDAR の反射強度、 r は return 情報である。

また、時刻 t に LiDAR 点群と対応して取得されたカメラ画像を

$$I_t^C \quad (7)$$

とする。

本研究では、各 LiDAR 点が ghost である確率を推定するため、次の 2 種類の推定器を構築する。

LiDAR のみを用いる場合は、

$$q_{i,t}^L = P(g_{i,t} = 1 \mid Z_t^L) \quad (8)$$

とする。

LiDAR 点群とカメラ画像を用いる場合は、

$$q_{i,t}^{LC} = P(g_{i,t} = 1 \mid Z_t^L, I_t^C) \quad (9)$$

とする。

ここで、 $g_{i,t} = 1$ は、時刻 t の点 i が鏡面またはガラス面による reflection、すなわち ghost 点であることを表す。

以降では、使用するモダリティを

$$m \in \{L, LC\} \quad (10)$$

で表し、各推定器の出力を統一的に

$$q_{i,t}^m \quad (11)$$

と表記する。

4.2 LiDAR 点と画像特徴の対応

LiDAR–Camera 融合手法では、LiDAR 点をカメラ画像上へ投影し、各点に対応する画像特徴を取得する。ただし、鏡面反射による ghost 点は鏡の奥側の仮想位置に生成されるため、通常の実在点と同じ意味での点–画素対応が成立するとは限らない。また、センサ間の視差、時刻ずれ、calibration 誤差および遮蔽により、単一画素からの hard sampling は不安定になり得る。このため、単純連結を比較用ベースラインとし、主手法では投影位置周辺の複数画像 token から特徴を選択する局所 cross-attention を用いる。

LiDAR 座標系の点 $\bar{z}_{i,t}$ をカメラ座標系へ変換し、画像平面へ投影する。

$$\mathbf{u}_{i,t} = \pi(\mathbf{T}_{CL}\bar{z}_{i,t}) \quad (12)$$

ここで、 $\mathbf{T}_{CL}$ は LiDAR 座標系からカメラ座標系への外部パラメータ、 $\pi(\cdot)$ はカメラ内部パラメータを用いた射影関数、 $\mathbf{u}_{i,t}$ は画像上の画素座標である。

カメラ画像から抽出した多段特徴マップを

$$\mathbf{F}_t^C = h_\phi(I_t^C) \quad (13)$$

とすると、単純連結ベースラインにおける点 i の画像特徴は、

$$\mathbf{f}_{i,t}^C = \text{Sample}(\mathbf{F}_t^C, \mathbf{u}_{i,t}) \quad (14)$$

で取得する。

主手法では、投影位置 $\mathbf{u}_{i,t}$ の周辺領域 $\mathcal{N}(\mathbf{u}_{i,t})$ から得る画像 token を $\mathbf{K}_{i,t}^C$ および $\mathbf{V}_{i,t}^C$ とし、LiDAR 点特徴を query とする。

$$\mathbf{c}_{i,t} = \text{CrossAttn}(\mathbf{W}_q \mathbf{f}_{i,t}^L, \mathbf{K}_{i,t}^C, \mathbf{V}_{i,t}^C). \quad (15)$$

この soft association は、単一の投影対応へ強く依存せずに有用な画像特徴を選択する構成であり、Transformer を用いた LiDAR–Camera 融合で有効性が示されている [6]。

画像外へ投影される点、カメラから不可視である点、または有効な画像特徴を取得できない点については、画像特徴の有効性を表す mask

$$a_{i,t}^C \in \{0, 1\} \quad (16)$$

を保持する。

4.3 Voxel レベル

世界座標系の voxel v について、LiDAR-only 手法と LiDAR–Camera 融合手法のそれぞれで、次の状態を推定する。

$$\gamma_{v,t}^m = P(G_v = 1 \mid Z_{1:t}^m), \quad (17)$$

$$o_{v,t}^m = P(O_v = 1 \mid Z_{1:t}^m), \quad m \in \{L, LC\}. \quad (18)$$

ここで、 $\gamma_{v,t}^m$ は voxel v に蓄積された観測が ghost 由来である確率、 $o_{v,t}^m$ は voxel v が物理的に占有されている確率である。

また、各 voxel について、以下の補助情報を保持する。

- ghost 側の累積証拠量
- non-ghost 側の累積証拠量
- occupancy の累積証拠量

- 観測フレーム数
- 有効証拠量
- 最終観測時刻

これにより、同じ確率値であっても、観測が少ないため不確実である状態と、多数の観測が矛盾している状態を区別する。

4.4 確率的デジタルツイン上の状態表現

従来の確率的デジタルツインを

$$D_t = \{S_{k,t}\} \quad (19)$$

とし、各構成要素の状態を

$$S_{k,t} = \{l_{k,t}, c_{k,t}, i_{k,t}\} \quad (20)$$

とする。

本研究では、空間を構成する voxel v について、

$$S_{v,t}^m = \{l_v, c_{v,t}, i_v, \gamma_{v,t}^m, o_{v,t}^m, e_{v,t}^m\} \quad (21)$$

へ拡張する。

ここで、 l_v は voxel の空間位置、 $c_{v,t}$ は意味クラス、 i_v は空間要素の識別子、 $\gamma_{v,t}^m$ は ghost 由来確率、 $o_{v,t}^m$ は物理占有確率、 $e_{v,t}^m$ は有効証拠量である。

4.5 3DRef から得る情報

表 1 3DRef の情報と本研究での用途

3DRef の情報	本研究での用途
XYZIR 点群	LiDAR-only および LiDAR-Camera 融合モデルの入力
点単位 6 クラスラベル	ghost 確率推定モデルの教師信号
RGB 画像	LiDAR-Camera 融合モデルの入力
カメラ内部・外部パラメータ	LiDAR 点と画像特徴の対応付け
LiDAR pose	点群の世界座標への変換
時系列フレーム	voxel 単位の時空間統合
ラベル付き 3D mesh	物理占有状態の ground truth
sequence 区分	未知環境に対する評価

主分類には、3DRef の次の 6 クラスを使用する。

$$\mathcal{C} = \{\text{normal, glass, mirror, other, reflection, obstacle}\}. \quad (22)$$

このうち、

$$g_{i,t} = 1 \iff y_{i,t} = \text{reflection} \quad (23)$$

と定義する。

Glass、Mirror および Obstacle behind Glass は、reflection とは異なり、実際に存在する表面または物体を表すため、ghost ではないクラスとして扱う。

LiDAR-only 手法と LiDAR-Camera 融合手法を公平に比較する主実験では、LiDAR 点群と RGB 画像の対応が得られるフレームのみを使用する。一方、LiDAR-only 手法については、利用可能な全 LiDAR フレームを用いた補助実験も行い、学習データ量の増加による影響を別途評価する。

5 全体処理フロー

本研究では、LiDAR-only 手法と LiDAR-Camera 融合手法を並列に構築し、点単位、voxel 単位および物理占有状態の各段階で比較する。

1. 3DRef から、LiDAR 点群、RGB 画像、点単位ラベル、センサ姿勢および calibration 情報を取得する。
2. PTV3 を用いて、XYZIR 点群から LiDAR 点特徴を抽出する。
3. 事前学習済み画像 encoder を用いて、RGB 画像から dense な画像特徴を抽出する。
4. LiDAR-only 分岐では LiDAR 点特徴から、LiDAR-Camera 分岐では局所 cross-attention および信頼度 gate による融合特徴から、6 クラス logits を出力する。
5. LiDAR pose で整列した近傍フレームの voxel token を Sparse Temporal Transformer で統合し、点単位 logits を更新する。
6. 各分類器の最終 logits を、validation データを用いて個別に確率校正する。
7. 各点について、 $q_{i,t}^L$ および $q_{i,t}^{LC}$ を得る。
8. LiDAR pose により、各点を世界座標系へ変換する。
9. 各手法について、voxel ごとに ghost 証拠を時空間統合する。
10. 各手法について、ghost 確率 $\gamma_{v,t}^m$ および物理占有確率 $o_{v,t}^m$ を更新する。
11. LiDAR-only と LiDAR-Camera 融合の確率的デジタルツインを比較する。

6 第 1 段階：点ごとの ghost 確率推定

6.1 LiDAR-only 分類器

LiDAR-only 分類器は、時刻 t の点群 Z_t^L を入力し、各点について 6 クラスの logits を出力する。主手法の backbone には Point Transformer V3 (PTv3) [3] を用いる。PTv3 は点群を空間充填曲線により serialization し、広い受容野を持つ attention を効率的に計算できるため、鏡・ガラス面の局所的な return 特性と、面の前後に分布する ghost 点の広域的な幾何関係を同時に扱えると期待される。入力特徴には XYZIR に加え、sensor ID、range および有効 return mask を用いる。

一方、3DRef 公式ベンチマークで高い性能を示す Cylinder3D を非 Transformer 型の主要ベースラインとする [1]。これにより、Transformer の導入効果と LiDAR-Camera 融合の効果を分離して評価する。

$$\ell_{i,t}^L = f_{\theta_L}(Z_t^L)_i \in \mathbb{R}^6. \quad (24)$$

softmax によって、

$$p_{i,t}^{L,(c)} = \frac{\exp(\ell_{i,t}^{L,(c)})}{\sum_{k=1}^6 \exp(\ell_{i,t}^{L,(k)})} \quad (25)$$

を得る。

未校正の ghost 確率は、

$$q_{i,t}^{L,\text{raw}} = p_{i,t}^{L,(\text{reflection})} \quad (26)$$

である。

6.2 LiDAR–Camera 融合分類器

LiDAR–Camera 融合分類器は、LiDAR 点群から抽出した特徴と、対応する画像特徴を統合する。

点 i の LiDAR 特徴を $f_{i,t}^L$ 、画像特徴を $f_{i,t}^C$ とすると、融合特徴を

$$f_{i,t}^{LC} = \Phi(f_{i,t}^L, a_{i,t}^C f_{i,t}^C) \quad (27)$$

とする。ここで、単純連結は比較用ベースラインとし、主手法の $\Phi(\cdot)$ には局所 cross-attention と信頼度 gate を使用する。

6.3 画像 encoder

画像 encoder には、自己教師あり学習により dense な局所特徴を獲得した DINOv3 [4] を用いる。3DRef で利用可能な RGB 画像数は LiDAR フレーム数より少ないため、初期実装では事前学習済み encoder を凍結し、特徴射影層および融合層のみを学習する。その後、validation 性能を監視しながら上位 block の fine-tuning を検討する。

また、画像上の glass、mirror および other reflective の位置を明示的に与える補助特徴として、3DRef で再学習した EBLNet による反射面確率 map を使用する [5, 1]。DINOv3 特徴のみ、反射面確率のみ、両者の併用を ablation で比較する。

6.4 局所 cross-attention と信頼度 gate

点 i の投影位置周辺にある複数スケールの画像 token に対して、LiDAR 点特徴を query とする局所 cross-attention を適用する。融合された画像文脈 $c_{i,t}$ の利用率を、

$$\rho_{i,t} = \sigma(\text{MLP}[f_{i,t}^L, c_{i,t}, a_{i,t}^C, H_{i,t}^C]) \quad (28)$$

とする。ここで、 $H_{i,t}^C$ は画像分岐の予測 entropy または不確実性である。最終的な融合特徴は、

$$f_{i,t}^{LC} = f_{i,t}^L \rho_{i,t} W_o c_{i,t} \quad (29)$$

とする。画像外、遮蔽、画像側の高 entropy または投影不整合がある場合には $\rho_{i,t}$ を小さくし、LiDAR 主体の推定へ連続的に戻れる構成とする。

分類器は、

$$\ell_{i,t}^{LC} = f_{\theta_{LC}}(Z_t^L, I_t^C)_i \in \mathbb{R}^6 \quad (30)$$

を出力する。

softmax によって、

$$p_{i,t}^{LC,(c)} = \frac{\exp(\ell_{i,t}^{LC,(c)})}{\sum_{k=1}^6 \exp(\ell_{i,t}^{LC,(k)})} \quad (31)$$

を得る。

未校正の ghost 確率は、

$$q_{i,t}^{LC,raw} = p_{i,t}^{LC,(reflection)} \quad (32)$$

である。

6.5 二値分類ではなく 6 クラス分類を使用する理由

本研究で最終的に利用するのは reflection クラスの確率であるが、学習時には 3DRef の 6 クラス分類を行う。

特に、

$$\text{reflection} \quad \text{と} \quad \text{obstacle behind glass} \quad (33)$$

の区別が重要である。

両者は LiDAR 上ではガラスや鏡の奥側に観測される可能性があるが、reflection は実在しない ghost 点であり、obstacle behind glass は実在する物体である。

カメラ画像は、鏡・ガラス面の境界、外観、透過像および反射像に関する情報を含むため、LiDAR のみでは困難な両クラスの識別を改善する可能性がある。

6.6 学習損失

LiDAR-only 分類器と LiDAR-Camera 融合分類器の双方について、同一形式の損失関数を用いる。

$$\mathcal{L}_{\text{seg}}^m = \mathcal{L}_{\text{WCE}}^m + \lambda_{\text{Lovasz}} \mathcal{L}_{\text{Lovasz}}^m, \quad m \in \{\text{L}, \text{LC}\}. \quad (34)$$

Weighted Cross Entropy により、少数クラスである Reflection の誤分類を重く評価する。Lovasz-Softmax により、Reflection を含む各クラスの IoU を改善する。

LiDAR-only 手法と LiDAR-Camera 融合手法の比較では、可能な限り同じ学習データ、データ分割、クラス重み、損失係数および最適化条件を用いる。

7 第 2 段階：短期時系列 Transformer

7.1 世界座標で整列した時系列 token

単一フレームの点特徴だけでなく、LiDAR pose を用いて近傍フレームを現在時刻の世界座標へ整列し、voxel ごとに特徴を集約する。時刻 t の voxel v における token を $\mathbf{h}_{v,t}^m$ とし、過去 K フレームの同一または近傍 voxel を参照する Sparse Temporal Transformer を構築する。

$$\hat{\mathbf{h}}_{v,t}^m = \text{TemporalAttn} \left(\mathbf{h}_{v,t}^m, \left\{ \mathbf{h}_{v',t-k}^m + \text{PE}(\mathbf{x}_{v'} - \mathbf{x}_v, \Delta t) \right\}_{(v',k) \in \mathcal{N}_{v,t}} \right). \quad (35)$$

ここで、 $\mathcal{N}_{v,t}$ は空間近傍と時間窓で制限した参照 token 集合である。全点間 attention は計算量が大きく、3DRef の系列数に対して過学習しやすいため使用しない。初期実装では $K = 3$ または 5 とし、静的環境を主対象として pose 補償後の局所 attention を行う。

時間的 LiDAR 点と画像特徴の統合は LiDAR semantic segmentation において高い性能を示しており [7]、共有 3D 位置表現と memory attention を組み合わせる設計も提案されている [8]。本研究ではこれらの考え方を小規模な voxel-level attention として実装し、点特徴へ補間して最終 logits を出力する。

7.2 短期学習と長期確率統合の役割分担

Sparse Temporal Transformer は数フレームの文脈から点単位分類を改善する学習型の短期統合として用いる。一方、後述する Beta evidence fusion は、校正済み確率を長期間にわたって解釈可能な形で蓄積する地図側の統合として維持する。すなわち、

$$\text{single-frame feature} \rightarrow \text{temporal feature} \rightarrow \text{calibrated probability} \rightarrow \text{Beta evidence fusion} \quad (36)$$

の順に処理する。

8 第3段階：ghost 確率の校正

各分類器の softmax 出力は、実際の正解頻度と一致するとは限らない。そのため、LiDAR-only 分類器と LiDAR-Camera 融合分類器について、短期時系列処理後の最終 logits に個別に Temperature Scaling を行う。単一フレーム条件については単一フレーム logits を校正し、異なる推論条件の temperature を共有しない。

モデル m の校正後確率を、

$$\tilde{p}_{i,t}^{m,(c)} = \frac{\exp\left(\ell_{i,t}^{m,(c)}/T_m\right)}{\sum_{k=1}^6 \exp\left(\ell_{i,t}^{m,(k)}/T_m\right)} \quad (37)$$

とする。

ここで、 T_m は validation データの Negative Log-Likelihood を最小化するように推定する。

校正後の ghost 確率は、

$$q_{i,t}^m = \tilde{p}_{i,t}^{m,(\text{reflection})}, \quad m \in \{\text{L, LC}\} \quad (38)$$

である。

LiDAR-only と LiDAR-Camera 融合の比較では、分類精度だけでなく、

- Negative Log-Likelihood
- Brier score
- Expected Calibration Error
- Reflection クラスの Classwise ECE
- Reliability diagram

を評価する。

これにより、カメラ画像の追加が、正解率だけでなく、ghost 確率の統計的信頼性を改善するかを検証する。

9 第4段階：世界座標への変換

各 LiDAR 点を、LiDAR pose を用いて世界座標系へ変換する。

$$\bar{\mathbf{x}}_{i,t}^W = \mathbf{T}_{WL,t} \bar{\mathbf{z}}_{i,t}. \quad (39)$$

この変換は LiDAR-only 手法と LiDAR-Camera 融合手法で共通である。したがって、同じ世界座標 $\mathbf{x}_{i,t}^W$ に対して、

$$(\mathbf{x}_{i,t}^W, q_{i,t}^L) \quad (40)$$

および

$$(\mathbf{x}_{i,t}^W, q_{i,t}^{\text{LC}}) \quad (41)$$

を登録する。

この段階では ghost 点の位置補正や鏡面反転は行わない。

10 第5段階：voxel 単位の ghost 確率統合

10.1 単一フレーム内の統合

voxel v に入る点の集合を

$$\mathcal{I}_{v,t} = \{i \mid \mathbf{x}_{i,t}^W \in v\} \quad (42)$$

とする。

モデルティ m における 1 フレーム内の ghost 証拠を、

$$\bar{q}_{v,t}^m = \frac{\sum_{i \in \mathcal{I}_{v,t}} w_{i,t}^m q_{i,t}^m}{\sum_{i \in \mathcal{I}_{v,t}} w_{i,t}^m} \quad (43)$$

として集約する。

初期実装では、

$$w_{i,t}^m = 1 \quad (44)$$

とし、後に距離、return、pose 精度、画像特徴の有効性、予測 entropy などを用いた重み付けを検討する。

10.2 時系列統合

各手法について、voxel v の ghost 確率を Beta 分布で表現する。

$$\Gamma_v^m \sim \text{Beta}(\alpha_{v,t}^m, \beta_{v,t}^m). \quad (45)$$

更新式は、

$$\alpha_{v,t}^m = \lambda \alpha_{v,t-1}^m + w_{v,t}^m \bar{q}_{v,t}^m, \quad (46)$$

$$\beta_{v,t}^m = \lambda \beta_{v,t-1}^m + w_{v,t}^m (1 - \bar{q}_{v,t}^m) \quad (47)$$

とする。

したがって、

$$\gamma_{v,t}^m = P(G_v = 1 \mid Z_{1:t}^m) = \frac{\alpha_{v,t}^m}{\alpha_{v,t}^m + \beta_{v,t}^m} \quad (48)$$

となる。

これは、校正済みの点単位 ghost 確率を soft count として累積する近似的な evidence fusion である。

10.3 関連した観測の過剰カウントの抑制

同一フレーム内の近接点および連続フレームの観測は独立ではない。そのため、

- 1 voxel・1 フレームにつき 1 回だけ更新する
- 1 フレームが与える証拠量に上限を設ける
- 時間的または空間的に近接したフレームの重みを下げる
- 画像特徴が無効な点は LiDAR-Camera 融合証拠の重みを下げる

といった処理を行う。

11 第 6 段階：物理占有確率の更新

11.1 物理表面由来確率

モダリティ m について、点 i が物理表面に由来する確率を、

$$r_{i,t}^m = 1 - q_{i,t}^m \quad (49)$$

と近似する。

6 クラス確率を明示的に用いる場合は、

$$\begin{aligned} r_{i,t}^m = & \tilde{p}_{i,t}^{m,(\text{normal})} + \tilde{p}_{i,t}^{m,(\text{glass})} + \tilde{p}_{i,t}^{m,(\text{mirror})} \\ & + \tilde{p}_{i,t}^{m,(\text{other})} + \tilde{p}_{i,t}^{m,(\text{obstacle})}. \end{aligned} \quad (50)$$

6 クラスの確率和が 1 である場合、

$$r_{i,t}^m = 1 - q_{i,t}^m \quad (51)$$

となる。

11.2 Log-odds による占有更新

モダリティ m に基づく voxel v の占有確率を、

$$o_{v,t}^m = P(O_v = 1 \mid Z_{1:t}^m) \quad (52)$$

とする。

その log-odds を、

$$L_{v,t}^{O,m} = \log \frac{o_{v,t}^m}{1 - o_{v,t}^m} \quad (53)$$

とする。

LiDAR 終端に対する occupied 更新を、

$$\Delta L_{v,t}^{\text{hit},m} = w_{i,t}^m (1 - q_{i,t}^m) l_{\text{hit}} \quad (54)$$

とする。

最終的な占有確率は、

$$o_{v,t}^m = \sigma \left(L_{v,t}^{O,m} \right) \quad (55)$$

で求める。

11.3 Free-space 更新

LiDAR 原点から観測終端までの ray 上の voxel について、

$$\Delta L_{v,t}^{\text{free},m} = w_{i,t}^m (1 - q_{i,t}^m) l_{\text{free}} \quad (56)$$

とする。ただし、

$$l_{\text{free}} < 0 \quad (57)$$

とする。

ghost 確率が高い観測は、終端の occupied 更新だけでなく、ray 上の free-space 更新への寄与も小さくする。

12 $P(G_v)$ と $P(O_v)$ の関係

モダリティ m について、 $\gamma_{v,t}^m$ は voxel v へ蓄積された観測の発生原因を表し、 $o_{v,t}^m$ は voxel v に物理表面が存在する確率を表す。

表 2 ghost 確率と物理占有確率の解釈

$\gamma_{v,t}^m$	$o_{v,t}^m$	解釈
低	高	実在表面として安定して観測される領域
高	低	ghost による偽障害物である可能性が高い領域
中	中	観測起源および物理占有状態が曖昧な領域
高	高	実在表面と ghost 観測が混在する領域
低	低	free 空間または未観測領域

確率に加え、有効証拠量 $e_{v,t}^m$ を保持することで、観測不足による不確実性と、多数の矛盾した観測による不確実性を区別する。

13 Ground Truth の構築

13.1 点単位 ghost ground truth

3DRef の点単位ラベルから、

$$g_{i,t}^* = \begin{cases} 1 & y_{i,t} = \text{reflection}, \\ 0 & \text{otherwise} \end{cases} \quad (58)$$

とする。

同一の $g_{i,t}^*$ を、LiDAR-only 分類器と LiDAR-Camera 融合分類器の教師および評価に使用する。

13.2 Voxel 単位 ghost ground truth

正解ラベル付き LiDAR 点群を世界座標へ変換し、voxel ごとの reflection 観測割合を、

$$\gamma_v^* = \frac{\sum_{i,t:\mathbf{x}_{i,t}^W \in v} g_{i,t}^*}{\sum_{i,t:\mathbf{x}_{i,t}^W \in v} 1} \quad (59)$$

として求める。

LiDAR-only と LiDAR-Camera 融合の公平な比較では、両手法に共通して利用できる LiDAR-RGB 対応フレームのみから γ_v^* を構築する。

13.3 物理占有 ground truth

ラベル付き 3D mesh を voxel 化し、

$$o_v^* = \begin{cases} 1 & \text{mesh が voxel } v \text{ と交差する,} \\ 0 & \text{観測可能であり、mesh が存在しない,} \\ \text{unknown} & \text{未観測または判定不能な領域} \end{cases} \quad (60)$$

とする。

LiDAR-only および LiDAR-Camera 融合で同一の o_v^* を使用する。

14 実験設計

14.1 モダリティ比較

主比較は、同一の LiDAR–RGB 対応フレームを用いて行う。

表 3 主要モデル比較

手法	特徴抽出・融合	位置付け
Cylinder3D	XYZIR	3DRef 公式ベースライン
PTv3 LiDAR-only	PTv3 + XYZIR	Transformer 特徴抽出
PTv3 Concat	PTv3 + 画像特徴連結	単純融合ベースライン
Proposed	PTv3 + 局所 cross-attention + gate	主提案手法

各モデルから、対応する $q_{i,t}^m$ 、 $\gamma_{v,t}^m$ および $o_{v,t}^m$ を構築する。主比較では、LiDAR-only と LiDAR–Camera で PTv3 の容量、時間窓、学習データおよび地図更新条件を共通化する。

比較では、学習データ、test データ、LiDAR backbone、クラス重み、確率校正方法、voxel サイズおよび時系列統合方法を可能な限り共通化する。

14.2 Occupancy 構築手法の比較

各モダリティについて、次の occupancy 構築手法を比較する。

表 4 Occupancy 構築方法の比較

手法	ghost の扱い
Raw occupancy	全 LiDAR 終端を occupied として登録
Hard GT removal	正解 Reflection 点を除去する理論上限
Hard prediction	$q_{i,t}^m > \tau$ の点を除去
Soft single-frame	$(1 - q_{i,t}^m)$ で重み付けし、時間統合しない
Temporal hard	時系列統合後の $\gamma_{v,t}^m$ を閾値処理
Proposed	校正済み確率の時系列統合 + soft occupancy

14.3 Ablation

次の要素について ablation study を行う。

- LiDAR-only / LiDAR–Camera 融合
- XYZI / XYZIR
- Cylinder3D / PTv3
- 二値分類 / 6 クラス分類
- 画像特徴なし / DINOv3 特徴 / EBLNet 反射面確率 / 両者
- DINOv3 凍結 / 上位 block の fine-tuning
- 単純な特徴連結 / 局所 cross-attention
- 信頼度 gate なし / あり

- 単一スケール画像 token / 複数スケール画像 token
- 未校正 softmax / 校正済み確率
- 単一フレーム / Sparse Temporal Transformer
- 時間窓 $K = 1, 3, 5$
- 単純平均 / Beta evidence fusion
- endpoint のみ / free-space を含む soft 更新
- 相関割引なし / あり

15 評価指標

15.1 点単位 ghost 推定

LiDAR-only と LiDAR-Camera 融合について、同一の test 点を用いて以下を比較する。

- Reflection Precision
- Reflection Recall
- Reflection F1
- Reflection IoU
- Reflection AUPRC
- Reflection と Obstacle behind Glass の混同行列

特に、LiDAR のみでは識別が困難と考えられる Reflection と Obstacle behind Glass の混同が、カメラ画像の導入により減少するかを評価する。

15.2 点単位確率校正

各手法の ghost 確率について、

- Negative Log-Likelihood
- Brier score
- Expected Calibration Error
- Reflection クラスの Classwise ECE
- Reliability diagram

を比較する。

15.3 Voxel 単位 ghost 確率

$\gamma_{v,t}^L$ および $\gamma_{v,t}^{LC}$ について、

- voxel-level Brier score
- voxel-level NLL
- voxel-level ECE
- voxel-level AUPRC
- 時系列統合に伴う確率変動
- 有効証拠量に対する予測誤差

を評価する。

15.4 物理占有状態

$o_{v,t}^L$ および $o_{v,t}^{LC}$ について、

- Occupancy IoU
- Occupancy Precision
- Occupancy Recall
- Occupancy Brier score
- Occupancy NLL
- False occupied voxel 数
- False occupied volume
- 実在 occupied voxel の False Negative 率

を評価する。

これにより、カメラ画像による点単位 ghost 推定の改善が、最終的な物理占有状態の推定にも寄与するかを検証する。

16 データ分割

隣接フレームが train と test へ混在することを避けるため、sequence 単位の Leave-One-Sequence-Out 評価を行う。

表 5 Leave-One-Sequence-Out 評価

Fold	Train / Validation	Test
1	Seq2、Seq3	Seq1
2	Seq1、Seq3	Seq2
3	Seq1、Seq2	Seq3

各 fold では、train sequence 内から連続した空間・時間区間を validation データとして分離する。

LiDAR-only と LiDAR-Camera 融合の主比較には、LiDAR 点群と RGB 画像の対応が確認できるフレームのみを使用する。test sequence は、モデル学習、特徴融合方法の選択、Temperature Scaling、閾値決定および voxel サイズの選択には使用しない。

17 実装フェーズ

17.1 Phase 1：データ対応関係の構築

3DRef の LiDAR 点群、RGB 画像、semantic label、LiDAR pose、カメラ内部・外部パラメータを読み込み、LiDAR 点と画像の対応付けを行う。

完了条件は、LiDAR 点を画像上へ投影し、点群と画像の位置関係が視覚的に整合することである。

17.2 Phase 2 : LiDAR-only ghost 分類

Cylinder3D + XYZIR の公式ベースラインを再現した後、PTv3 + XYZIR の LiDAR-only 分類器を学習し、

$$q_{i,t}^{\text{L,raw}} \quad (61)$$

を出力する。

完了条件は、両 backbone について任意フレームの 6 クラス logits を保存し、Reflection クラスの Precision、Recall、IoU および AUPRC を同一 test データで比較できることである。

17.3 Phase 3 : Transformer による LiDAR–Camera 融合

DINOv3 画像 encoder、EBLNet 反射面確率 map、LiDAR 点と局所画像 token の対応付け、cross-attention および信頼度 gate を実装し、

$$q_{i,t}^{\text{LC,raw}} \quad (62)$$

を出力する。

完了条件は、単純特徴連結と提案融合手法を LiDAR-only 手法と同一の test データ上で比較し、画像特徴が無効または不確実な点における gate の挙動を可視化できることである。

17.4 Phase 4 : 短期時系列 Transformer

LiDAR pose によって近傍フレームを整列し、voxel token に対する Sparse Temporal Transformer を実装する。単一フレーム、 $K = 3$ および $K = 5$ を比較する。

完了条件は、各モダリティについて単一フレームと時系列モデルの Reflection IoU、AUPRC および計算量を比較できることである。

17.5 Phase 5 : 確率校正

単一フレームおよび時系列モデルの最終 logits に対して、それぞれ Temperature Scaling を行い、

$$q_{i,t}^{\text{L}}, \quad q_{i,t}^{\text{LC}} \quad (63)$$

を得る。

完了条件は、校正前後の NLL、Brier score、ECE および Reliability diagram を比較できることである。

17.6 Phase 6 : 世界座標統合と ghost 確率地図

LiDAR pose を用いて点群を世界座標へ変換し、LiDAR-only および LiDAR–Camera 融合のそれぞれについて、

$$\gamma_{v,t}^{\text{L}}, \quad \gamma_{v,t}^{\text{LC}} \quad (64)$$

を構築する。

完了条件は、両手法の voxel 単位 ghost 確率地図を同一座標系で比較できることである。

17.7 Phase 7：物理占有確率と最終評価

各手法について、

$$o_{v,t}^L, \quad o_{v,t}^{LC} \quad (65)$$

を構築し、ラベル付き 3D mesh から生成した ground truth と比較する。

完了条件は、LiDAR-only と LiDAR-Camera 融合について、点単位、voxel 単位および occupancy 単位の全指標を比較できることである。

18 研究仮説

18.1 H1：カメラ画像による ghost 識別性能の向上

LiDAR-Camera 融合手法は、LiDAR-only 手法よりも Reflection クラスの識別性能を改善する。特に、

$$\text{AUPRC}_{LC} > \text{AUPRC}_L \quad (66)$$

および

$$\text{IoU}_{LC} > \text{IoU}_L \quad (67)$$

を仮説とする。

18.2 H2：カメラ画像による確率校正性能の向上

LiDAR-Camera 融合手法は、LiDAR-only 手法よりも ghost 確率の校正誤差を低減する。

$$\text{Brier}_{LC} < \text{Brier}_L \quad (68)$$

および

$$\text{ECE}_{LC} < \text{ECE}_L \quad (69)$$

を仮説とする。

18.3 H3：時系列統合による ghost 確率の安定化

各モダリティにおいて、世界座標上での時系列統合は、単一フレーム推定よりも voxel 単位の ghost 確率を改善する。

$$\text{NLL}_{\text{temporal}}^m < \text{NLL}_{\text{single}}^m, \quad m \in \{L, LC\} \quad (70)$$

を仮説とする。

18.4 H4：LiDAR-Camera 融合による物理占有推定の改善

LiDAR-Camera 融合による soft occupancy 更新は、LiDAR-only による更新よりも、ghost に起因する false occupancy を低減する。

$$\text{FP}_{LC} < \text{FP}_L \quad (71)$$

および

$$\text{Brier}_{\text{occ,L,C}} < \text{Brier}_{\text{occ,L}} \quad (72)$$

を仮説とする。

また、提案する soft occupancy 更新は、ハード除去よりも実在物体の誤除去を抑制する。

$$\text{FN}_{\text{soft}} < \text{FN}_{\text{hard}} \quad (73)$$

を仮説とする。

19 研究の新規性

本研究の中心的な貢献は、次の 5 点である。

1. LiDAR 観測点の発生原因を、校正された ghost 確率として表現すること。
2. PTv3 による点群特徴、DINOv3 および反射面確率による画像特徴を、局所 cross-attention と信頼度 gate で統合し、反射環境特有の不確かな点-画素対応を soft に扱うこと。
3. LiDAR-only と LiDAR-Camera 融合について、点単位の分類性能だけでなく、確率校正性能を比較すること。
4. Sparse Temporal Transformer による短期特徴統合と、Beta evidence fusion による長期確率統合を役割分担させ、ghost 確率を確率的デジタルツインの状態として保持すること。
5. ghost 由来確率と物理占有確率を分離し、カメラ情報の導入が最終的な物理占有状態の推定に与える効果まで評価すること。

既存のハードな ghost 除去では、

$$\text{ghost} \Rightarrow \text{delete} \quad (74)$$

という二値処理を行う。

本研究では、モダリティ m ごとに、

$$\text{observation} \Rightarrow \begin{cases} \text{ghost evidence} & : q_{i,t}^m, \\ \text{physical occupancy evidence} & : 1 - q_{i,t}^m \end{cases} \quad (75)$$

として、判断の不確実性を保持したまま時空間デジタルツインへ統合する。

20 最終的な研究成果物

研究終了時には、各 voxel について、LiDAR-only 手法および LiDAR-Camera 融合手法のそれぞれに対し、次の情報を保持する確率的デジタルツインを構築する。

- voxel coordinate
- ghost probability
- physical occupancy probability
- ghost evidence amount
- non-ghost evidence amount
- physical occupancy evidence amount
- observation count
- effective evidence amount

- last observation time

可視化では、以下を出力する。

- LiDAR-only の ghost 確率マップ
- LiDAR–Camera 融合の ghost 確率マップ
- 両手法の ghost 確率差分
- LiDAR-only の physical occupancy map
- LiDAR–Camera 融合の physical occupancy map
- ground-truth occupancy との差分
- uncertainty および evidence map
- Raw occupancy および Hard removal との差分

これにより、カメラ画像の追加が ghost 点の識別精度に与える効果だけでなく、観測不確実性の時空間統合および物理占有状態の推定に与える効果まで、一貫して評価する。

参考文献

- [1] Xiting Zhao and Sören Schwertfeger. 3DRef: 3d dataset and benchmark for reflection detection in RGB and lidar data. In *International Conference on 3D Vision (3DV)*, 2024.
- [2] Zhijian Liu, Haotian Tang, Alexander Amini, Xinyu Yang, Huizi Mao, Daniela Rus, and Song Han. BEVFusion: Multi-task multi-sensor fusion with unified bird’s-eye view representation. In *IEEE International Conference on Robotics and Automation (ICRA)*, pp. 2774–2781, 2023.
- [3] Xiaoyang Wu, Li Jiang, Peng-Shuai Wang, Zhijian Liu, Xihui Liu, Yu Qiao, Wanli Ouyang, Tong He, and Hengshuang Zhao. Point transformer v3: Simpler, faster, stronger. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 4840–4851, 2024.
- [4] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, et al. DINOv3. *arXiv preprint arXiv:2508.10104*, 2025.
- [5] Hao He, Xiangtai Li, Guangliang Cheng, Jianping Shi, Yunhai Tong, Gaofeng Meng, Véronique Prinet, and LuBin Weng. Enhanced boundary learning for glass-like object segmentation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 15859–15868, 2021.
- [6] Xuyang Bai, Zeyu Hu, Xinge Zhu, Qingqiu Huang, Yilun Chen, Hongbo Fu, and Chiew-Lan Tai. TransFusion: Robust LiDAR-camera fusion for 3d object detection with transformers. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1090–1099, 2022.
- [7] Xiaopei Wu, Yuenan Hou, Xiaoshui Huang, Binbin Lin, Tong He, Xinge Zhu, Yuexin Ma, Boxi Wu, Haifeng Liu, Deng Cai, and Wanli Ouyang. TASeg: Temporal aggregation network for LiDAR semantic segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 15311–15320, 2024.
- [8] Jianyun Xu, Song Wang, Ziqian Ni, Chunyong Hu, Sheng Yang, Jianke Zhu, and Qiang Li. SAM4D: Segment anything in camera and LiDAR streams. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 28535–28545, 2025.