

鏡面・ガラス反射環境における LiDAR 観測の 確率的デジタルツイン構築に関する研究計画

2026 年 7 月 18 日

1 研究目的

本研究では、鏡・ガラスを含む環境で取得された LiDAR 観測について、各点を単純に「残す／削除する」と決定するのではなく、

$$P(G_v = 1 \mid Z_{1:t}), \quad (1)$$

$$P(O_v = 1 \mid Z_{1:t}) \quad (2)$$

を別々に推定・保持する確率的デジタルツインを構築する。ここで、 G_v は voxel v に蓄積された観測が ghost 由来である事象、 O_v は voxel v が実際の物理表面によって占有されている事象、 $Z_{1:t}$ は時刻 1 から t までの観測を表す。

本研究では、観測点が物理的な占有の証拠としてどの程度信頼できるかを確率的に評価し、その信頼度を世界座標上で時空間的に統合する。これにより、ghost 点を物理障害物として誤登録することと、ghost らしい点を一律に削除することで実在物体を失うことの双方を抑制する。

また、ghost 点の発生は LiDAR 点単体の反射強度や return 情報だけでなく、鏡面・ガラス面の位置、境界および外観と関係する。このため本研究では、LiDAR のみを用いる単一モーダル手法と、LiDAR 点群およびカメラ画像を統合するマルチモーダル手法を構築し、両者の ghost 確率推定性能を比較する。

具体的には、LiDAR のみを用いた場合の点 i の ghost 確率を

$$q_{i,t}^L = P(G_{i,t} = 1 \mid Z_t^L) \quad (3)$$

とし、LiDAR およびカメラ画像を用いた場合の ghost 確率を

$$q_{i,t}^{LC} = P(G_{i,t} = 1 \mid Z_t^L, I_t) \quad (4)$$

とする。ここで、 Z_t^L は時刻 t の LiDAR 観測、 I_t は対応するカメラ画像である。

これらの確率を世界座標上の voxel へ時空間的に統合し、LiDAR のみの場合と LiDAR–Camera 融合の場合について、ghost 確率 $P(G_v = 1 \mid Z_{1:t})$ および物理占有確率 $P(O_v = 1 \mid Z_{1:t})$ の精度を比較する。

以上より、本研究の目的は以下のようにまとめられる。

LiDAR 観測点が鏡面反射による ghost である確率を推定し、その確率を世界座標上で時空間的に統合することで、反射環境における物理的占有状態の不確実性を表現する確率的デジタルツイン構築手法を提案する。さらに、LiDAR のみを用いる手法と LiDAR–Camera 融合手法を比較し、カメラ画像に含まれる鏡面・ガラス面の外観情報が ghost 確率推定および物理占有状態推定に与える効果を明らかにする。

1.1 使用するデータセットと出典

本研究では、主データセットとして 3DRef (*3D Dataset and Benchmark for Reflection Detection in RGB and Lidar Data*) を使用する。3DRef は、鏡、ガラス、白板、モニタなどの反射面を含む屋内環境で取得された、RGB 画像、multi-return LiDAR 点群、2D/3D semantic label、LiDAR pose、ラベル付き 3D ground-truth mesh を含む公開データセットである。公式プロジェクトページでは、3 系列の屋内シーケンス、48,024 個のラベル付き LiDAR 点群、3,799 枚のラベル付き RGB 画像、Ouster、Livox、Hesai の 3 種類の LiDAR センサによるデータが提供されている。

本研究では、このうち LiDAR 点群、点単位の semantic label、LiDAR pose、ラベル付き 3D mesh を主に使用する。点単位ラベルは ghost 確率推定モデルの教師信号として用い、LiDAR pose は各点を世界座標系へ変換するために用いる。また、ラベル付き 3D mesh は物理占有状態の ground truth を構築するために利用する。

出典は以下の通りである。

- Xiting Zhao and Sören Schwertfeger, “3DRef: 3D Dataset and Benchmark for Reflection Detection in RGB and Lidar Data,” 3DV, 2024。
- 3DRef 公式プロジェクトページ : <https://3dref.github.io/>

2 リサーチクエスチョン

本研究では、以下のリサーチクエスチョンを設定する。

- RQ1 LiDAR の位置、反射強度および return 情報のみから、各観測点が ghost である確率をどの程度正確かつ適切に校正された形で推定できるか。
- RQ2 LiDAR 点群にカメラ画像の外観情報を統合することで、LiDAR のみを用いる場合と比較して、ghost 点の識別性能および確率校正性能は向上するか。
- RQ3 LiDAR のみ、または LiDAR–Camera 融合によって推定した ghost 確率を世界座標上で時空間的に統合することで、通常の occupancy map やハードな ghost 点除去と比較して、ghost による偽の占有を抑制しつつ、実在する物体の占有状態を保持できるか。

3 推定対象とデータから得られる情報

3.1 観測レベル

時刻 t に取得された LiDAR 点群を

$$Z_t^L = \{z_{1,t}, \dots, z_{N_t,t}\} \quad (5)$$

とする。各 LiDAR 点は、

$$z_{i,t} = (x_{i,t}, y_{i,t}, z_{i,t}, I_{i,t}^L, r_{i,t}) \quad (6)$$

で表す。ここで、 (x, y, z) は LiDAR 座標系における位置、 I^L は LiDAR の反射強度、 r は return 情報である。

また、時刻 t に LiDAR 点群と対応して取得されたカメラ画像を

$$I_t^C \quad (7)$$

とする。

本研究では、各 LiDAR 点が ghost である確率を推定するため、次の 2 種類の推定器を構築する。
LiDAR のみを用いる場合は、

$$q_{i,t}^L = P(g_{i,t} = 1 \mid Z_t^L) \quad (8)$$

とする。

LiDAR 点群とカメラ画像を用いる場合は、

$$q_{i,t}^{LC} = P(g_{i,t} = 1 \mid Z_t^L, I_t^C) \quad (9)$$

とする。

ここで、 $g_{i,t} = 1$ は、時刻 t の点 i が鏡面またはガラス面による reflection、すなわち ghost 点であることを表す。

以降では、使用するモダリティを

$$m \in \{L, LC\} \quad (10)$$

で表し、各推定器の出力を統一的に

$$q_{i,t}^m \quad (11)$$

と表記する。

3.2 LiDAR 点と画像特徴の対応

LiDAR–Camera 融合手法では、LiDAR 点をカメラ画像上へ投影し、各点に対応する画像特徴を取得する。
LiDAR 座標系の点 $\bar{z}_{i,t}$ をカメラ座標系へ変換し、画像平面へ投影する。

$$\mathbf{u}_{i,t} = \pi(\mathbf{T}_{CL} \bar{z}_{i,t}) \quad (12)$$

ここで、 $\mathbf{T}_{CL}$ は LiDAR 座標系からカメラ座標系への外部パラメータ、 $\pi(\cdot)$ はカメラ内部パラメータを用いた射影関数、 $\mathbf{u}_{i,t}$ は画像上の画素座標である。

カメラ画像から抽出した特徴マップを

$$\mathbf{F}_t^C = h_\phi(I_t^C) \quad (13)$$

とすると、点 i に対応する画像特徴は、

$$\mathbf{f}_{i,t}^C = \text{Sample}(\mathbf{F}_t^C, \mathbf{u}_{i,t}) \quad (14)$$

で取得する。

画像外へ投影される点、カメラから不可視である点、または有効な画像特徴を取得できない点については、画像特徴の有効性を表す mask

$$a_{i,t}^C \in \{0, 1\} \quad (15)$$

を保持する。

3.3 Voxel レベル

世界座標系の voxel v について、LiDAR-only 手法と LiDAR–Camera 融合手法のそれぞれで、次の状態を推定する。

$$\gamma_{v,t}^m = P(G_v = 1 \mid Z_{1:t}^m), \quad (16)$$

$$o_{v,t}^m = P(O_v = 1 \mid Z_{1:t}^m), \quad m \in \{L, LC\}. \quad (17)$$

ここで、 $\gamma_{v,t}^m$ は voxel v に蓄積された観測が ghost 由来である確率、 $o_{v,t}^m$ は voxel v が物理的に占有されている確率である。

また、各 voxel について、以下の補助情報を保持する。

- ghost 側の累積証拠量
- non-ghost 側の累積証拠量
- occupancy の累積証拠量
- 観測フレーム数
- 有効証拠量
- 最終観測時刻

これにより、同じ確率値であっても、観測が少ないため不確実である状態と、多数の観測が矛盾している状態を区別する。

3.4 確率的デジタルツイン上の状態表現

従来の確率的デジタルツインを

$$D_t = \{S_{k,t}\} \quad (18)$$

とし、各構成要素の状態を

$$S_{k,t} = \{l_{k,t}, c_{k,t}, i_{k,t}\} \quad (19)$$

とする。

本研究では、空間を構成する voxel v について、

$$S_{v,t}^m = \{l_v, c_{v,t}, i_v, \gamma_{v,t}^m, o_{v,t}^m, e_{v,t}^m\} \quad (20)$$

へ拡張する。

ここで、 l_v は voxel の空間位置、 $c_{v,t}$ は意味クラス、 i_v は空間要素の識別子、 $\gamma_{v,t}^m$ は ghost 由来確率、 $o_{v,t}^m$ は物理占有確率、 $e_{v,t}^m$ は有効証拠量である。

3.5 3DRef から得る情報

表 1 3DRef の情報と本研究での用途

3DRef の情報	本研究での用途
XYZIR 点群	LiDAR-only および LiDAR-Camera 融合モデルの入力
点単位 6 クラスラベル	ghost 確率推定モデルの教師信号
RGB 画像	LiDAR-Camera 融合モデルの入力
カメラ内部・外部パラメータ	LiDAR 点と画像特徴の対応付け
LiDAR pose	点群の世界座標への変換
時系列フレーム	voxel 単位の時空間統合
ラベル付き 3D mesh	物理占有状態の ground truth
sequence 区分	未知環境に対する評価

主分類には、3DRef の次の 6 クラスを使用する。

$$\mathcal{C} = \{\text{normal, glass, mirror, other, reflection, obstacle}\}. \quad (21)$$

このうち、

$$g_{i,t} = 1 \iff y_{i,t} = \text{reflection} \quad (22)$$

と定義する。

Glass、Mirror および Obstacle behind Glass は、reflection とは異なり、実際に存在する表面または物体を表すため、ghost ではないクラスとして扱う。

LiDAR-only 手法と LiDAR-Camera 融合手法を公平に比較する主実験では、LiDAR 点群と RGB 画像の対応が得られるフレームのみを使用する。一方、LiDAR-only 手法については、利用可能な全 LiDAR フレームを用いた補助実験も行い、学習データ量の増加による影響を別途評価する。

4 全体処理フロー

本研究では、LiDAR-only 手法と LiDAR-Camera 融合手法を並列に構築し、点単位、voxel 単位および物理占有状態の各段階で比較する。

1. 3DRef から、LiDAR 点群、RGB 画像、点単位ラベル、センサ姿勢および calibration 情報を取得する。
2. LiDAR-only 分類器を用いて、各点の 6 クラス logits を出力する。
3. LiDAR-Camera 融合分類器を用いて、各点の 6 クラス logits を出力する。
4. 各分類器の softmax 出力を、validation データを用いて個別に確率校正する。
5. 各点について、 $q_{i,t}^L$ および $q_{i,t}^{LC}$ を得る。
6. LiDAR pose により、各点を世界座標系へ変換する。
7. 各手法について、voxel ごとに ghost 証拠を時空間統合する。
8. 各手法について、ghost 確率 $\gamma_{v,t}^m$ および物理占有確率 $o_{v,t}^m$ を更新する。
9. LiDAR-only と LiDAR-Camera 融合の確率的デジタルツインを比較する。

5 第 1 段階：点ごとの ghost 確率推定

5.1 LiDAR-only 分類器

LiDAR-only 分類器は、時刻 t の点群 Z_t^L を入力し、各点について 6 クラスの logits を出力する。

$$\ell_{i,t}^L = f_{\theta_L}(Z_t^L)_i \in \mathbb{R}^6. \quad (23)$$

softmax によって、

$$p_{i,t}^{L,(c)} = \frac{\exp(\ell_{i,t}^{L,(c)})}{\sum_{k=1}^6 \exp(\ell_{i,t}^{L,(k)})} \quad (24)$$

を得る。

未校正の ghost 確率は、

$$q_{i,t}^{L,\text{raw}} = p_{i,t}^{L,(\text{reflection})} \quad (25)$$

である。

5.2 LiDAR-Camera 融合分類器

LiDAR-Camera 融合分類器は、LiDAR 点群から抽出した特徴と、対応する画像特徴を統合する。

点 i の LiDAR 特徴を $f_{i,t}^L$ 、画像特徴を $f_{i,t}^C$ とすると、融合特徴を

$$f_{i,t}^{LC} = \Phi(f_{i,t}^L, a_{i,t}^C f_{i,t}^C) \quad (26)$$

とする。ここで、 $\Phi(\cdot)$ は連結、加重和、attention などによる特徴融合関数である。

分類器は、

$$\ell_{i,t}^{LC} = f_{\theta_{LC}}(Z_t^L, I_t^C)_i \in \mathbb{R}^6 \quad (27)$$

を出力する。

softmax によって、

$$p_{i,t}^{LC,(c)} = \frac{\exp(\ell_{i,t}^{LC,(c)})}{\sum_{k=1}^6 \exp(\ell_{i,t}^{LC,(k)})} \quad (28)$$

を得る。

未校正の ghost 確率は、

$$q_{i,t}^{LC,raw} = p_{i,t}^{LC,(reflection)} \quad (29)$$

である。

5.3 二値分類ではなく 6 クラス分類を使用する理由

本研究で最終的に利用するのは reflection クラスの確率であるが、学習時には 3DRef の 6 クラス分類を行う。

特に、

$$\text{reflection} \quad \text{と} \quad \text{obstacle behind glass} \quad (30)$$

の区別が重要である。

両者は LiDAR 上ではガラスや鏡の奥側に観測される可能性があるが、reflection は実在しない ghost 点であり、obstacle behind glass は実在する物体である。

カメラ画像は、鏡・ガラス面の境界、外観、透過像および反射像に関する情報を含むため、LiDAR のみでは困難な両クラスの識別を改善する可能性がある。

5.4 学習損失

LiDAR-only 分類器と LiDAR-Camera 融合分類器の双方について、同一形式の損失関数を用いる。

$$\mathcal{L}_{seg}^m = \mathcal{L}_{WCE}^m + \lambda_{Lovasz} \mathcal{L}_{Lovasz}^m, \quad m \in \{L, LC\}. \quad (31)$$

Weighted Cross Entropy により、少数クラスである Reflection の誤分類を重く評価する。Lovasz-Softmax により、Reflection を含む各クラスの IoU を改善する。

LiDAR-only 手法と LiDAR-Camera 融合手法の比較では、可能な限り同じ学習データ、データ分割、クラス重み、損失係数および最適化条件を用いる。

6 第 2 段階：ghost 確率の校正

各分類器の softmax 出力は、実際の正解頻度と一致するとは限らない。そのため、LiDAR-only 分類器と LiDAR-Camera 融合分類器について、個別に Temperature Scaling を行う。

モデル m の校正後確率を、

$$\tilde{p}_{i,t}^{m,(c)} = \frac{\exp\left(\ell_{i,t}^{m,(c)}/T_m\right)}{\sum_{k=1}^6 \exp\left(\ell_{i,t}^{m,(k)}/T_m\right)} \quad (32)$$

とする。

ここで、 T_m は validation データの Negative Log-Likelihood を最小化するように推定する。

校正後の ghost 確率は、

$$q_{i,t}^m = \tilde{p}_{i,t}^{m,(\text{reflection})}, \quad m \in \{\text{L, LC}\} \quad (33)$$

である。

LiDAR-only と LiDAR-Camera 融合の比較では、分類精度だけでなく、

- Negative Log-Likelihood
- Brier score
- Expected Calibration Error
- Reflection クラスの Classwise ECE
- Reliability diagram

を評価する。

これにより、カメラ画像の追加が、正解率だけでなく、ghost 確率の統計的信頼性を改善するかを検証する。

7 第3段階：世界座標への変換

各 LiDAR 点を、LiDAR pose を用いて世界座標系へ変換する。

$$\mathbf{x}_{i,t}^W = \mathbf{T}_{WL,t} \mathbf{z}_{i,t}. \quad (34)$$

この変換は LiDAR-only 手法と LiDAR-Camera 融合手法で共通である。したがって、同じ世界座標 $\mathbf{x}_{i,t}^W$ に対して、

$$(\mathbf{x}_{i,t}^W, q_{i,t}^L) \quad (35)$$

および

$$(\mathbf{x}_{i,t}^W, q_{i,t}^{\text{LC}}) \quad (36)$$

を登録する。

この段階では ghost 点の位置補正や鏡面反転は行わない。

8 第4段階：voxel 単位の ghost 確率統合

8.1 単一フレーム内の統合

voxel v に入る点の集合を

$$\mathcal{I}_{v,t} = \{i \mid \mathbf{x}_{i,t}^W \in v\} \quad (37)$$

とする。

モデルティ m における 1 フレーム内の ghost 証拠を、

$$\bar{q}_{v,t}^m = \frac{\sum_{i \in \mathcal{I}_{v,t}} w_{i,t}^m q_{i,t}^m}{\sum_{i \in \mathcal{I}_{v,t}} w_{i,t}^m} \quad (38)$$

として集約する。

初期実装では、

$$w_{i,t}^m = 1 \quad (39)$$

とし、後に距離、return、pose 精度、画像特徴の有効性、予測 entropy などを用いた重み付けを検討する。

8.2 時系列統合

各手法について、voxel v の ghost 確率を Beta 分布で表現する。

$$\Gamma_v^m \sim \text{Beta}(\alpha_{v,t}^m, \beta_{v,t}^m). \quad (40)$$

更新式は、

$$\alpha_{v,t}^m = \lambda \alpha_{v,t-1}^m + w_{v,t}^m \bar{q}_{v,t}^m, \quad (41)$$

$$\beta_{v,t}^m = \lambda \beta_{v,t-1}^m + w_{v,t}^m (1 - \bar{q}_{v,t}^m) \quad (42)$$

とする。

したがって、

$$\gamma_{v,t}^m = P(G_v = 1 \mid Z_{1:t}^m) = \frac{\alpha_{v,t}^m}{\alpha_{v,t}^m + \beta_{v,t}^m} \quad (43)$$

となる。

これは、校正済みの点単位 ghost 確率を soft count として累積する近似的な evidence fusion である。

8.3 関連した観測の過剰カウントの抑制

同一フレーム内の近接点および連続フレームの観測は独立ではない。そのため、

- 1 voxel・1 フレームにつき 1 回だけ更新する
- 1 フレームが与える証拠量に上限を設ける
- 時間的または空間的に近接したフレームの重みを下げる
- 画像特徴が無効な点は LiDAR-Camera 融合証拠の重みを下げる

といった処理を行う。

9 第 5 段階：物理占有確率の更新

9.1 物理表面由来確率

モデルティ m について、点 i が物理表面に由来する確率を、

$$r_{i,t}^m = 1 - q_{i,t}^m \quad (44)$$

と近似する。

6 クラス確率を明示的に用いる場合は、

$$r_{i,t}^m = \tilde{p}_{i,t}^{m,(\text{normal})} + \tilde{p}_{i,t}^{m,(\text{glass})} + \tilde{p}_{i,t}^{m,(\text{mirror})} + \tilde{p}_{i,t}^{m,(\text{other})} + \tilde{p}_{i,t}^{m,(\text{obstacle})}. \quad (45)$$

6 クラスの確率和が 1 である場合、

$$r_{i,t}^m = 1 - q_{i,t}^m \quad (46)$$

となる。

9.2 Log-odds による占有更新

モデルティ m に基づく voxel v の占有確率を、

$$o_{v,t}^m = P(O_v = 1 \mid Z_{1:t}^m) \quad (47)$$

とする。

その log-odds を、

$$L_{v,t}^{O,m} = \log \frac{o_{v,t}^m}{1 - o_{v,t}^m} \quad (48)$$

とする。

LiDAR 終端に対する occupied 更新を、

$$\Delta L_{v,t}^{\text{hit},m} = w_{i,t}^m (1 - q_{i,t}^m) l_{\text{hit}} \quad (49)$$

とする。

最終的な占有確率は、

$$o_{v,t}^m = \sigma \left(L_{v,t}^{O,m} \right) \quad (50)$$

で求める。

9.3 Free-space 更新

LiDAR 原点から観測終端までの ray 上の voxel について、

$$\Delta L_{v,t}^{\text{free},m} = w_{i,t}^m (1 - q_{i,t}^m) l_{\text{free}} \quad (51)$$

とする。ただし、

$$l_{\text{free}} < 0 \quad (52)$$

とする。

ghost 確率が高い観測は、終端の occupied 更新だけでなく、ray 上の free-space 更新への寄与も小さくする。

10 $P(G_v)$ と $P(O_v)$ の関係

モデルティ m について、 $\gamma_{v,t}^m$ は voxel v へ蓄積された観測の発生原因を表し、 $o_{v,t}^m$ は voxel v に物理表面が存在する確率を表す。

確率に加え、有効証拠量 $e_{v,t}^m$ を保持することで、観測不足による不確実性と、多数の矛盾した観測による不確実性を区別する。

表 2 ghost 確率と物理占有確率の解釈

$\gamma_{v,t}^m$	$o_{v,t}^m$	解釈
低	高	実在表面として安定して観測される領域
高	低	ghost による偽障害物である可能性が高い領域
中	中	観測起源および物理占有状態が曖昧な領域
高	高	実在表面と ghost 観測が混在する領域
低	低	free 空間または未観測領域

11 Ground Truth の構築

11.1 点単位 ghost ground truth

3DRef の点単位ラベルから、

$$g_{i,t}^* = \begin{cases} 1 & y_{i,t} = \text{reflection}, \\ 0 & \text{otherwise} \end{cases} \quad (53)$$

とする。

同一の $g_{i,t}^*$ を、LiDAR-only 分類器と LiDAR-Camera 融合分類器の教師および評価に使用する。

11.2 Voxel 単位 ghost ground truth

正解ラベル付き LiDAR 点群を世界座標へ変換し、voxel ごとの reflection 観測割合を、

$$\gamma_v^* = \frac{\sum_{i,t:\mathbf{x}_{i,t}^W \in v} g_{i,t}^*}{\sum_{i,t:\mathbf{x}_{i,t}^W \in v} 1} \quad (54)$$

として求める。

LiDAR-only と LiDAR-Camera 融合の公平な比較では、両手法に共通して利用できる LiDAR-RGB 対応フレームのみから γ_v^* を構築する。

11.3 物理占有 ground truth

ラベル付き 3D mesh を voxel 化し、

$$o_v^* = \begin{cases} 1 & \text{mesh が voxel } v \text{ と交差する,} \\ 0 & \text{観測可能であり、mesh が存在しない,} \\ \text{unknown} & \text{未観測または判定不能な領域} \end{cases} \quad (55)$$

とする。

LiDAR-only および LiDAR-Camera 融合で同一の o_v^* を使用する。

12 実験設計

12.1 モダリティ比較

主比較は、同一の LiDAR-RGB 対応フレームを用いて行う。

比較では、学習データ、test データ、LiDAR backbone、クラス重み、確率校正方法、voxel サイズおよび時系列統合方法を可能な限り共通化する。

表 3 モダリティ比較

手法	入力	出力
LiDAR-only	XYZIR 点群	$q_{i,t}^L, \gamma_{v,t}^L, o_{v,t}^L$
LiDAR-Camera	XYZIR 点群 + RGB 画像	$q_{i,t}^{LC}, \gamma_{v,t}^{LC}, o_{v,t}^{LC}$

12.2 Occupancy 構築手法の比較

各モダリティについて、次の occupancy 構築手法を比較する。

表 4 Occupancy 構築方法の比較

手法	ghost の扱い
Raw occupancy	全 LiDAR 終端を occupied として登録
Hard GT removal	正解 Reflection 点を除去する理論上限
Hard prediction	$q_{i,t}^m > \tau$ の点を除去
Soft single-frame	$(1 - q_{i,t}^m)$ で重み付けし、時間統合しない
Temporal hard	時系列統合後の $\gamma_{v,t}^m$ を閾値処理
Proposed	校正済み確率の時系列統合 + soft occupancy

12.3 Ablation

次の要素について ablation study を行う。

- LiDAR-only / LiDAR-Camera 融合
- XYZI / XYZIR
- 二値分類 / 6 クラス分類
- 画像特徴なし / 画像特徴あり
- 単純な特徴連結 / attention による融合
- 未校正 softmax / 校正済み確率
- 単一フレーム / 時系列統合
- 単純平均 / Beta evidence fusion
- endpoint のみ / free-space を含む soft 更新
- 相関割引なし / あり

13 評価指標

13.1 点単位 ghost 推定

LiDAR-only と LiDAR-Camera 融合について、同一の test 点を用いて以下を比較する。

- Reflection Precision
- Reflection Recall
- Reflection F1

- Reflection IoU
- Reflection AUPRC
- Reflection と Obstacle behind Glass の混同行列

特に、LiDAR のみでは識別が困難と考えられる Reflection と Obstacle behind Glass の混同が、カメラ画像の導入により減少するかを評価する。

13.2 点単位確率校正

各手法の ghost 確率について、

- Negative Log-Likelihood
- Brier score
- Expected Calibration Error
- Reflection クラスの Classwise ECE
- Reliability diagram

を比較する。

13.3 Voxel 単位 ghost 確率

$\gamma_{v,t}^L$ および $\gamma_{v,t}^{LC}$ について、

- voxel-level Brier score
- voxel-level NLL
- voxel-level ECE
- voxel-level AUPRC
- 時系列統合に伴う確率変動
- 有効証拠量に対する予測誤差

を評価する。

13.4 物理占有状態

$o_{v,t}^L$ および $o_{v,t}^{LC}$ について、

- Occupancy IoU
- Occupancy Precision
- Occupancy Recall
- Occupancy Brier score
- Occupancy NLL
- False occupied voxel 数
- False occupied volume
- 実在 occupied voxel の False Negative 率

を評価する。

これにより、カメラ画像による点単位 ghost 推定の改善が、最終的な物理占有状態の推定にも寄与するかを検証する。

14 データ分割

隣接フレームが train と test へ混在することを避けるため、sequence 単位の Leave-One-Sequence-Out 評価を行う。

表 5 Leave-One-Sequence-Out 評価

Fold	Train / Validation	Test
1	Seq2、Seq3	Seq1
2	Seq1、Seq3	Seq2
3	Seq1、Seq2	Seq3

各 fold では、train sequence 内から連続した空間・時間区間を validation データとして分離する。

LiDAR-only と LiDAR-Camera 融合の主比較には、LiDAR 点群と RGB 画像の対応が確認できるフレームのみを使用する。test sequence は、モデル学習、特徴融合方法の選択、Temperature Scaling、閾値決定および voxel サイズの選択には使用しない。

15 実装フェーズ

15.1 Phase 1：データ対応関係の構築

3DRef の LiDAR 点群、RGB 画像、semantic label、LiDAR pose、カメラ内部・外部パラメータを読み込み、LiDAR 点と画像の対応付けを行う。

完了条件は、LiDAR 点を画像上へ投影し、点群と画像の位置関係が視覚的に整合することである。

15.2 Phase 2：LiDAR-only ghost 分類

LiDAR-only 分類器を学習し、

$$q_{i,t}^{\text{L,raw}} \quad (56)$$

を出力する。

完了条件は、任意フレームについて 6 クラス logits を保存し、Reflection クラスの Precision、Recall、IoU および AUPRC を算出できることである。

15.3 Phase 3：LiDAR-Camera 融合 ghost 分類

画像 encoder、LiDAR 点と画像特徴の対応付け、および特徴融合機構を実装し、

$$q_{i,t}^{\text{LC,raw}} \quad (57)$$

を出力する。

完了条件は、LiDAR-only 手法と同一の test データ上で点単位性能を比較できることである。

15.4 Phase 4：確率校正

各分類器に対して Temperature Scaling を行い、

$$q_{i,t}^{\text{L}}, \quad q_{i,t}^{\text{LC}} \quad (58)$$

を得る。

完了条件は、校正前後の NLL、Brier score、ECE および Reliability diagram を比較できることである。

15.5 Phase 5：世界座標統合と ghost 確率地図

LiDAR pose を用いて点群を世界座標へ変換し、LiDAR-only および LiDAR–Camera 融合のそれぞれについて、

$$\gamma_{v,t}^L, \quad \gamma_{v,t}^{LC} \quad (59)$$

を構築する。

完了条件は、両手法の voxel 単位 ghost 確率地図を同一座標系で比較できることである。

15.6 Phase 6：物理占有確率と最終評価

各手法について、

$$o_{v,t}^L, \quad o_{v,t}^{LC} \quad (60)$$

を構築し、ラベル付き 3D mesh から生成した ground truth と比較する。

完了条件は、LiDAR-only と LiDAR–Camera 融合について、点単位、voxel 単位および occupancy 単位の全指標を比較できることである。

16 研究仮説

16.1 H1：カメラ画像による ghost 識別性能の向上

LiDAR–Camera 融合手法は、LiDAR-only 手法よりも Reflection クラスの識別性能を改善する。特に、

$$\text{AUPRC}_{LC} > \text{AUPRC}_L \quad (61)$$

および

$$\text{IoU}_{LC} > \text{IoU}_L \quad (62)$$

を仮説とする。

16.2 H2：カメラ画像による確率校正性能の向上

LiDAR–Camera 融合手法は、LiDAR-only 手法よりも ghost 確率の校正誤差を低減する。

$$\text{Brier}_{LC} < \text{Brier}_L \quad (63)$$

および

$$\text{ECE}_{LC} < \text{ECE}_L \quad (64)$$

を仮説とする。

16.3 H3：時系列統合による ghost 確率の安定化

各モダリティにおいて、世界座標上での時系列統合は、単一フレーム推定よりも voxel 単位の ghost 確率を改善する。

$$\text{NLL}_{\text{temporal}}^m < \text{NLL}_{\text{single}}^m, \quad m \in \{L, LC\} \quad (65)$$

を仮説とする。

16.4 H4：LiDAR–Camera 融合による物理占有推定の改善

LiDAR–Camera 融合による soft occupancy 更新は、LiDAR-only による更新よりも、ghost に起因する false occupancy を低減する。

$$FP_{LC} < FP_L \quad (66)$$

および

$$Brier_{occ,LC} < Brier_{occ,L} \quad (67)$$

を仮説とする。

また、提案する soft occupancy 更新は、ハード除去よりも実在物体の誤除去を抑制する。

$$FN_{soft} < FN_{hard} \quad (68)$$

を仮説とする。

17 研究の新規性

本研究の中心的な貢献は、次の 4 点である。

1. LiDAR 観測点の発生原因を、校正された ghost 確率として表現すること。
2. LiDAR-only と LiDAR–Camera 融合について、点単位の分類性能だけでなく、確率校正性能を比較すること。
3. ghost 確率を世界座標上で時空間的に統合し、確率的デジタルツインの状態として保持すること。
4. ghost 由来確率と物理占有確率を分離し、カメラ情報の導入が最終的な物理占有状態の推定に与える効果まで評価すること。

既存のハードな ghost 除去では、

$$\text{ghost} \Rightarrow \text{delete} \quad (69)$$

という二値処理を行う。

本研究では、モダリティ m ごとに、

$$\text{observation} \Rightarrow \begin{cases} \text{ghost evidence} & : q_{i,t}^m, \\ \text{physical occupancy evidence} & : 1 - q_{i,t}^m \end{cases} \quad (70)$$

として、判断の不確実性を保持したまま時空間デジタルツインへ統合する。

18 最終的な研究成果物

研究終了時には、各 voxel について、LiDAR-only 手法および LiDAR–Camera 融合手法のそれぞれに対し、次の情報を保持する確率的デジタルツインを構築する。

- voxel coordinate
- ghost probability
- physical occupancy probability
- ghost evidence amount
- non-ghost evidence amount

- physical occupancy evidence amount
- observation count
- effective evidence amount
- last observation time

可視化では、以下を出力する。

- LiDAR-only の ghost 確率マップ
- LiDAR-Camera 融合の ghost 確率マップ
- 両手法の ghost 確率差分
- LiDAR-only の physical occupancy map
- LiDAR-Camera 融合の physical occupancy map
- ground-truth occupancy との差分
- uncertainty および evidence map
- Raw occupancy および Hard removal との差分

これにより、カメラ画像の追加が ghost 点の識別精度に与える効果だけでなく、観測不確実性の時空間統合および物理占有状態の推定に与える効果まで、一貫して評価する。